

דוח פרויקט

כריית נתונים: סט נתוני סרטים (IMDb & Wikipedia)

אביה שפירא | 213277064

הפרויקט כולל תהליך עבודה של חיבור נתונים מקבצי CSV קיימים, המתעדים סרטים באתר IMDb, בשילוב עם מידע נוסף ששלפתי מתוך ויקיפדיה באמצעות Web Scraping, כפי שלמדנו בכיתה.

במהלך העבודה על הפרויקט, נדרשתי לקבל מספר החלטות שהשפיעו על תוצאות סט הנתונים הסופי.

המהלך הראשון היה איחוד הנתונים של IMDb באמצעות מזהה חד-ערכי משותף בין הטבלאות, ויצירת טבלה אחת הכוללת את כל הסרטים הרלוונטיים, על פי הקריטריונים הבאים:

1. סרטים ששמן מתחיל באותיות G או H.
2. אורך סרט שבין 60 ל-300 דקות.
3. סרטים שיצאו להקרנה עד שנת 2024 (כולל).

לאחר מכן, לקחתי את סט הנתונים שקיבלתי וביצעתי עבור כל סרט חיפוש אוטומטי אחר הערך שלו בוויקיפדיה. על מנת לצמצם את מרחב הטעות, החיפוש בוצע לפי שילוב של שם ושנה (במידה וקיימת), תוך בדיקת גרסאות שונות של כתובות URL לשמירה בוויקיפדיה.

שלב שליפת הנתונים היה המאתגר ביותר, בעיקר בשל העובדה שזמן הריצה עבור כ-17,250 סרטים ארך כמעט יממה שלמה. בשל כך, ביצעתי תחילה בדיקות על מספר סרטים כדי לוודא את תקינות השליפה, ורק לאחר מכן הרצתי את התהליך על הכמות המלאה.

בשלב הבא, סידרתי את הנתונים שהתקבלו מוויקיפדיה על פי הנחיות המטלה. המשימה המורכבת ביותר הייתה נרמול הערכים הכספיים למיליוני דולרים; כיוון שבוויקיפדיה המידע מוזן באופן חופשי על ידי מגוון רחב של משתמשים, הוא כולל שילוב של טקסט, הערות שוליים וסוגי מטבעות רבים. לכן, בניתי פונקציה המבצעת המרה ליחידות של מיליונים תוך המרת מטבעות זרים לדולר. חשוב לציין כי מאחר ושער המטבעות בחישוב הוא ממוצע מודרני ולא בהכרח תואם לשער ההיסטורי בשנה בה יצא הסרט, נתונים אלו עלולים לכלול טעויות.

בשלב איחוד הטבלאות (IMDb וויקיפדיה), קיבלתי החלטה להסיר מהסט סרטים בעלי שם ושנת יציאה זהים לחלוטין. זאת במטרה למנוע הטיה של הנתונים, שכן המידע מוויקיפדיה עשוי להתאים רק לאחד מהם. החלטה זו הובילה להסרה של כ-220 סרטים – כמות שולית ביחס לכלל הנתונים, אך כזו שתורמת לאמינות הסט.

בנוסף, זיהיתי כי במקרים של שמות סרטים זהים (ללא שנת הצלבה), נתוני ויקיפדיה שוכפלו למספר סרטים ב-IMDb. כדי לפתור זאת, ביצעתי דירוג של הסרטים לפי רמת הפופולריות שלהם (מספר הצבעות ב-IMDb) והחלטתי להשאיר את הנתונים הכספיים רק עבור הסרט המוכר ביותר, מתוך הנחה סבירה שהמידע בוויקיפדיה מתייחס אליו. בשאר המופעים, הנתונים הכספיים אופסו כדי למנוע כפילויות.

החלטה זו אמנם מצמצמת את כמות הנתונים הסופית, ואף עלולה להוביל גם היא לשגיאות בנתונים שהתקבלו אך לדעתי היא צמצמה את מרחב הטעות שהיה לולא הייתי מקבלת אותה.

לאחר תהליך הניקוי והצלבת הנתונים, אחוז החוסרים בעמודות הכספיות (Budget, BoxOffice) עומד על כ-90%.

חשוב לציין: חוסר זה נובע מהחלטה מודעת לפסול נתונים משוכפלים או חשודים כפי שציינתי למעלה וזאת כדי להבטיח את אמינות המדגם.

לאחר איסוף ואיחוד הנתונים, התקבל סט נתונים סופי של 17,033 סרטים.

סט הנתונים הסופי כולל בתוכו את העמודות הבאות:

- **Tconst** (object)
- **primaryTitle** (object)
- **startYear** (float64)
- **runtimeMinutes** (float64)
- **Genres** (object)
- **averageRating** (float64)
- **numVotes** (int64)
- **lead_actors_ids** (object)
- **Language** (object)
- **Country** (object)
- **Budget** (float64)
- **BoxOffice** (float64)
- **Plot** (object)

פירוט הערכים החסרים בכל עמודה:

עמודה	כמות ערכים חסרים	כמות באחוזים
Tconst	-	-
primaryTitle	-	-
startYear	-	-
runtimeMinutes	-	-
Genres	353	2.07%
averageRating	-	-

-	-	numVotes
%10.37	1767	lead_actors_ids
%71.67	10159	Language
%74.79	10843	Country
%91.22	15287	Budget
%89.53	14906	BoxOffice
%70.68	7702	Plot