

דוח פרויקט

כריית נתונים: סט נתוני סרטים (IMDb & Wikipedia)

אביה שפירא | 213277064

הפרויקט כולל תהליך עבודה של חיבור נתונים מקבצי CSV קיימים, המתעדים סרטים באתר IMDb, בשילוב עם מידע נוסף ששלפתי מתוך ויקיפדיה באמצעות Web Scraping, כפי שלמדנו בכיתה.

במהלך העבודה על הפרויקט, נדרשתי לקבל מספר החלטות שהשפיעו על תוצאות סט הנתונים הסופי.

המהלך הראשון היה איחוד הנתונים של IMDb באמצעות מזהה חד-ערכי משותף בין הטבלאות, ויצירת טבלה אחת הכוללת את כל הסרטים הרלוונטיים, על פי הקריטריונים הבאים:

1. סרטים ששמן מתחיל באותיות G או H.
2. אורך סרט שבין 60 ל-300 דקות.
3. סרטים שיצאו להקרנה עד שנת 2024 (כולל).

לאחר מכן, לקחתי את סט הנתונים שקיבלתי וביצעתי עבור כל סרט חיפוש אוטומטי אחר הערך שלו בוויקיפדיה. על מנת לצמצם את מרחב הטעות, החיפוש בוצע לפי שילוב של שם ושנה (במידה וקיימת), תוך בדיקת גרסאות שונות של כתובות URL לשמירה בוויקיפדיה.

שלב שליפת הנתונים היה המאתגר ביותר, בעיקר בשל העובדה שזמן הריצה עבור כ-17,250 סרטים ארך כמעט יממה שלמה. בשל כך, ביצעתי תחילה בדיקות על מספר סרטים כדי לוודא את תקינות השליפה, ורק לאחר מכן הרצתי את התהליך על הכמות המלאה.

בשלב הבא, סידרתי את הנתונים שהתקבלו מוויקיפדיה על פי הנחיות המטלה. המשימה המורכבת ביותר הייתה נרמול הערכים הכספיים למיליוני דולרים; כיוון שבוויקיפדיה המידע מוזן באופן חופשי על ידי מגוון רחב של משתמשים, הוא כולל שילוב של טקסט, הערות שוליים וסוגי מטבעות רבים. לכן, בניתי פונקציה המבצעת המרה ליחידות של מיליונים תוך המרת מטבעות זרים לדולר. חשוב לציין כי מאחר ושער המטבעות בחישוב הוא ממוצע מודרני ולא בהכרח תואם לשער ההיסטורי בשנה בה יצא הסרט, נתונים אלו עלולים לכלול טעויות.

בשלב איחוד הטבלאות (IMDb וויקיפדיה), קיבלתי החלטה להסיר מהסט סרטים בעלי שם ושנת יציאה זהים לחלוטין. זאת במטרה למנוע הטיה של הנתונים, שכן המידע מוויקיפדיה עשוי להתאים רק לאחד מהם. החלטה זו הובילה להסרה של כ-111 סרטים – כמות שולית ביחס לכלל הנתונים, אך כזו שתורמת לאמינות הסט.

חשוב לציין, שאני מבינה שכאשר יש סרטים עם שם זהה, יש סיכוי שנשאב מוויקיפדיה מידע ששייך לסרט אחר בשם זהה, ולכן לפני השימוש בנתונים יש לשקול הסרה של כל הערכים עם השם הזהה. בשלב זה בחרתי שלא להסיר אותם על מנת לקבל סט נתונים רחב ולהשאיר את זה לשיקול המשתמשים בנתונים.

לאחר איסוף ואיחוד הנתונים, התקבל סט נתונים סופי של 17,139 סרטים.

סט הנתונים הסופי כולל בתוכו את העמודות הבאות:

- **Tconst** (object)
- **primaryTitle** (object)
- **startYear** (float64)
- **runtimeMinutes** (float64)
- **Genres** (object)
- **averageRating** (float64)
- **numVotes** (int64)
- **lead_actors_ids** (object)
- **Language** (object)
- **Country** (object)
- **Budget** (float64)
- **BoxOffice** (float64)
- **Plot** (object)

פירוט הערכים החסרים בכל עמודה:

עמודה	כמות ערכים חסרים	כמות באחוזים
Tconst	-	-
primaryTitle	-	-
startYear	-	-
runtimeMinutes	-	-
Genres	354	%2.065
averageRating	-	-
numVotes	-	-
lead_actors_ids	1773	%10.34
Language	10206	%59.54
Country	10897	%63.58
Budget	15375	%89.707684
BoxOffice	15008	%87.566369
Plot	7704	%44.950114